# Informacija in kodi

UN2-1-AV 2024/2025

Kodiranje vira

Simon Dobrišek november 2024

## Teme predavanja

Uvod

Kodna drevesa

Gospodarno kodiranje

Enakomerni kodi

Neenakomerni kodi

Gospodarni kodi

Huffmanov kod

Aritmetični kod

Kod Lempela, Ziva in Welcha (LZW)

#### Uvod

Znaki, ki jih oddaja vir informacije, pogosto ne zadoščajo tehničnim zahtevam, ki jih postavlja kanal.

Na primer, pri pisni komunikaciji uporabljamo približno sto znakov (velike in male črke abecede, številčni znaki med nič in devet ter ločila).

Če želimo napisano besedilo (sporočilo) shraniti v pomnilniku računalnika ali ga prenesti na oddaljeno mesto po elektronski pošti, moramo znake, ki smo jih uporabljali pri pisanju besedila, zamenjati z ustreznimi nizi dvojiških<sup>1</sup> znakov.

Prirejanju znakov ene abecede znakom druge abecede pravimo kodiranje.

<sup>&</sup>lt;sup>1</sup>Velja za današnjo stopnjo razvoja tovrstne tehnologije.

#### Uvod

S kodiranjem, ki mu pravimo *kodiranje vira*, prirejamo znakom iz abecede vira znake (nize znakov) iz abecede koda<sup>2</sup>



Vzemimo, da je dan diskreten vir informacije s

- ightharpoonup končno abecedo  $A = \{x_1, x_2, ..., x_a\}$  ter
- končna množica znakov  $B = \{z_1, z_2, ..., z_b\}$ , ki ji pravimo abeceda koda.

<sup>&</sup>lt;sup>2</sup>Abecedo koda sestavljajo znaki, ki jih kanal lahko "sprejme".

#### Uvod - kod vira

#### **DEFINICIJA 5.1** Kod vira je trojica (A, B, f), kjer so:

- A abeceda vira moči a,
- ▶ B abeceda koda moči b in
- ▶ f injektivna³ preslikava

$$f: A \longrightarrow E$$
,

kjer je  $E = B^m$  ali  $E = B^1 \cup B^2 \cup \cdots \cup B^m$  množica kodnih zamenjav  $f(x_i)$ , m pa naravno število.

 $<sup>^3</sup>$ Preslikava f je injektivna, če je f(x) slika kvečjemu enega  $x \in A$ .

#### Primer 5.1

Vzemimo, da je  $B=\{0,1\}$  ter m=3. V tem primeru je množica kodnih zamenjav

$$E = B^3 = \{000, 001, 010, 011, 100, 101, 110, 111\}$$

ali

$$E = B^{1} \cup B^{2} \cup B^{3} =$$

$$= \{0, 1, 00, 01, 10, 11, 000, 001, 010, 011, 100, 101, 110, 111\}$$



#### Uvod - enakomerni in neenakomerni kod

**DEFINICIJA 5.2** Če je  $E = B^m$ , to je, če je množica kodnih zamenjav  $f(x_i)$ ; i = 1, 2, ..., a, sestavljena le iz nizov znakov iz množice B dolžine m, pravimo takšnemu kodu vira **enakomerni kod**.

**DEFINICIJA 5.3** Če je množica kodnih zamenjav sestavljena iz enočlenih, dvočlenih, tročlenih itn. nizov iz množice B, to je, če je  $E = B^1 \cup B^2 \cup \cdots B^m$ , pravimo takšnemu kodu vira **neenakomerni kod**.

Neenakomerni kod lahko vsebuje kodne zamenjave, ki so predpone drugim kodnim zamenjavam koda.

**DEFINICIJA 5.4** Pravimo, da je k-člena kodna zamenjava  $f(x_i)$  predpona l-členi kodni zamenjavi  $f(x_j)$ , k < l, če je  $f(x_i)$  enaka prvim k znakom  $f(x_j)$ . Zadnjim l-k znakom  $f(x_j)$  pravimo pripona.

#### Primer 5.2

Na primer, če sta kodni zamenjavi neenakomernega koda  $f(x_i) = 1$  in  $f(x_j) = 101$ , je  $f(x_i)$  predpona  $f(x_j)$ , niz 01 pa je pripona  $f(x_j)$ .

Uporabni so le tisti kodi, ki jih je možno enolično dekodirati.

**DEFINICIJA 5.5** Kod vira (A, B, f) je možno enolično dekodirati, če je možno enolično dekodirati vsak niz kodnih zamenjav iz množice E.

Enakomerne kode je možno enolično dekodirati, če je  $a \leq b^m$ , medtem ko je neenakomerne kode možno enolično dekodirati, če prestanejo preizkus z algoritmom **Sardinasa in Pattersona**.

## Uvod - algoritem Sardinasa in Pattersona

#### Začetek postopka

- 1. korak Postavi  $E' \leftarrow E$ .
- 2. korak V E' poišči par nizov znakov iz abecede koda, kjer je en niz predpona drugemu nizu. Dodaj v E' njuno pripono, vendar le v primeru, da je različna od pripon, ki si jih dodal v E' v predhodnih ponovitvah 2. koraka.
- 3. korak Ponavljaj 2. korak, dokler:
  - a) v E' ne moreš najti para nizov, kjer je en niz predpona drugemu nizu (končaj preizkus – kod je možno enolično dekodirati),
     ali
  - b) v E' si dodal pripono, ki je kodna zamenjava iz E (končaj preizkus – kod ni možno enolično dekodirati).

Konec postopka

#### Uvod - trenutni in netrenutni kodi

Kode, ki jih je možno enolično dekodirati, delimo na trenutne in netrenutne kode.

Sporočila, ki so kodirana s trenutnim kodom, lahko sprotno (to je, med sprejemanjem) dekodiramo. Sporočila, ki so kodirana z netrenutnim kodom, lahko dekodiramo šele po sprejetju koda celotnega sporočila.

Vsi enakomerni kodi so trenutni. Neenakomerni kodi so lahko trenutni ali netrenutni.

**DEFINICIJA 5.6** Neenakomerni kod je trenuten kod, če ne vsebuje kodne zamenjave, ki bi bila predpona kakšne druge kodne zamenjave.

#### Primer 5.3

Vzemimo, da je dan vir informacije, ki oddaja znake iz abecede  $A = \{x_1, x_2, x_3\}$ , ter abeceda koda  $B = \{0, 1\}$ .

Oglejmo si naslednje kode vira:

Α	$kod\ \mathcal{A}$	kod $\mathcal{B}_1$	kod $\mathcal{B}_2$	$kod\;\mathcal{C}$	$kod\; \mathcal{D}$
<i>x</i> <sub>1</sub>	00	0	0	0	0
<i>x</i> <sub>2</sub>	01	1	01	10	01
<i>X</i> 3	10	01	10	11	11

Preslikava, ki preslika  $x_i$  v  $f(x_i)$ , je za vse kode injektivna.

Kod  $\mathcal{A}$  je enakomerni kod, kodi  $\mathcal{B}_1, \mathcal{B}_2, \mathcal{C}$  in  $\mathcal{D}$  so neenakomerni.

Enakomeren kod  ${\cal A}$  lahko enolično dekodiramo, ker je 3 < 2 $^2$ .

Ali je možno enolično dekodirati tudi neenakomerne kode  $\mathcal{B}_1$ ,  $\mathcal{B}_2$ ,  $\mathcal{C}$  in  $\mathcal{D}$  se prepričamo tako, da jih podvržemo preizkusu s postopkom

Sardinasa in Pattersona.

odiamasa mi i associas								
kod	1. korak	2. korak	2. korak	3. korak				
$\mathcal{B}_1$	$E' = \{0, 1, 01\}$	$E' = \{0, 1, 01, 1\}$		3 b)				
$\mathcal{B}_2$	$E' = \{0, 01, 10\}$	$E' = \{0, 01, 10, 1\}$	$E' = \{0, 01, 10, 1, 0\}$	3 b)				
$\mathcal C$	$E' = \{0, 10, 11\}$			3 a)				
$\mathcal{D}$	$E' = \{0, 01, 11\}$	$E' = \{0, 01, 11, 1\}$		3 a)				

Opazimo, da obeh neenakomernih kodov  $\mathcal B$  ni mogoče enolično dekodirati.

Na primer, niz znakov  $x_1x_2x_3$  kodiramo s kodom  $\mathcal{B}_1$  z nizom znakov 0101, ki ga lahko dekodiramo kot  $x_1x_2x_3$ ,  $x_1x_2x_1x_2$ ,  $x_3x_3$  ali  $x_3x_1x_2$ .

Podobno, niz znakov  $x_1x_3x_3x_3$  kodiramo s kodom  $\mathcal{B}_2$  z nizom znakov 0101010, ki ga lahko dekodiramo kot  $x_1x_3x_3x_3$  ali  $x_2x_2x_2x_1$ .

Ker koda  $\mathcal{B}_1$  in  $\mathcal{B}_2$  ne omogočata enoličnega dekodiranja vseh sporočil, ki jih odda vir, sta neuporabna.

Za neenakomerna koda  $\mathcal C$  in  $\mathcal D$  ni možno najti niza kodnih zamenjav, ki ga ne bi bilo možno enolično dekodirati, pri čemer kod  $\mathcal C$  omogoča sprotno dekodiranje, kod  $\mathcal D$  pa dekodiranje po sprejemu koda celotnega sporočila.

Vzemimo za primer, da moramo dekodirati niz znakov 0111111, ki ga je ustvaril kod  $\mathcal{C}$ .

V nizu je prvi znak kodna zamenjava znaka  $x_1$ , drugi znak ni kodna zamenjava koda C, zato počakamo na sprejem tretjega znaka koda sporočila.

Drugi in tretji znak koda sporočila sta kodna zamenjava znaka  $x_3$ .

Četrti znak koda sporočila ni kodna zamenjava koda C, zato četrti in peti znak, ter podobno šesti in sedmi znak, koda sporočila enolično dekodiramo kot znaka sporočila  $x_3x_3$ .

Vzemimo sedaj, da moramo dekodirati niz znakov iz abecede koda 0111111, ki ga je ustvaril kod  $\mathcal{D}$ .

V sprejetem nizu je prvi znak kodna zamenjava znaka  $x_1$ , prva dva znaka pa kodna zamenjava znaka  $x_2$ .

Da bi odločili, ali je prvi dekodirani znak  $x_1$  ali  $x_2$ , moramo počakati na konec sprejema celotnega sporočila.

Če dekodiramo prvi znak sporočila kot  $x_2$ , bomo dekodirali naslednja dva znaka kot  $x_3$ , zadnji znak sprejetega niza 1 pa ne bomo mogli dekodirati, ker 1 ni kodna zamenjava koda  $\mathcal{D}$ .

Če pa dekodiramo prvi znak sporočila kot  $x_1$ , bomo lahko dekodirali naslednjih šest znakov sprejetega niza kot kodne zamenjave niza treh znakov sporočila  $x_3x_3x_3$ .

Kod  $\mathcal{D}$  očitno ni trenuten kod, vendar ga je možno enolično dekodirati.

Kod  $\mathcal C$  smo lahko sprotno dekodirali, ker ne vsebuje kodne zamenjave, ki bi bila predpona kakšne druge kodne zamenjave.

V kodu  $\mathcal{D}$  pa je kodna zamenjava  $f(x_1)$  predpona kodne zamenjave  $f(x_2)$ , zato ga lahko enolično dekodiramo šele po sprejetju koda celotnega sporočila.

#### Kodna drevesa

Opazimo, da je možno ločevati trenutne kode od ostalih neenakomernih kodov, ki jih je možno enolično dekodirati, le z ugotavljanjem, da kod ne vsebuje kodne zamenjave, ki bi bila predpona kakšne druge kodne zamenjave.

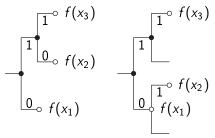
To najlažje naredimo, če kod ponazorimo s kodnim drevesom.

- Kodna drevesa so večnivojska drevesa s stopnjami vozlišč, enakimi številu znakov abecede koda b.
- Veje, ki izstopajo iz vozlišč, označimo z znaki iz množice  $B = \{z_1, z_2, ..., z_b\}.$
- Kodne zamenjave določajo nizi oznak (zaporedij) vej, ki se začnejo v korenu drevesa in končujejo v kateremkoli vozlišču v notranjosti drevesa.

## Kodna drevesa - primer

#### Primer 5.4

Kodni drevesi kodov  $\mathcal C$  in  $\mathcal D$  iz primera 5.3 sta ponazorjeni na sliki.



Opazimo, da se kodne zamenjave koda  $\mathcal{D}$  nahajajo tudi v notranjih vozliščih kodnega drevesa, kar ne velja za kod  $\mathcal{C}$ , ki je trenutni.

Za trenutne kode namreč velja, da se kodna drevesa ne vejijo od izbrane kodne zamenjave naprej, ker v trenutnem kodu nobena kodna zamenjava ni predpona kakšni drugi kodni zamenjavi.

## Gospodarno kodiranje

Če si pri kodiranju vira zastavimo še nalogo, da bomo informacijo, ki jo odda vir informacije, zakodirali z *najmanjšim* možnim številom znakov iz abecede koda, pravimo takšnemu kodiranju vira *gospodarno kodiranje*.

Vzemimo, da diskreten vir odda znak  $x_i$  z verjetnostjo

$$P(x_i) = p_i,$$
  $i = 1, ..., a,$   $\sum_{i=1}^{a} p_i = 1,$ 

ter da je dolžina kodne zamenjave  $f(x_i)$  v kodu (A, B, f) enaka  $n_i$   $(n_i$  je število znakov abecede B v kodni zamenjavi  $f(x_i) \in E$ ).

## Mera gospodarnosti koda

**DEFINICIJA 5.7** Mera gospodarnosti koda vira (A, B, f) je povprečna dolžina njegovih kodnih zamenjav

$$\overline{n} = \sum_{i=1}^{a} p_i n_i.$$

Oglejmo si, kateri izmed štirih kodov iz primera 5.3 je najgospodarnejši, to je, kateri izmed štirih kodov ima najmanjšo povprečno dolžino kodnih zamenjav  $\overline{n}$ .

## Mera gospodarnosti koda

#### Primer 5.5

Vzemimo, da vir informacije iz primera 5.3 oddaja znake iz abecede  $A = \{x_1, x_2, x_3\}$  v skladu s porazdelitvijo verjetnosti P = (0.5, 0.3, 0.2).

V tem primeru je povprečna dolžina kodnih zamenjav koda  $\mathcal{A}$  enaka  $\overline{n}_{\mathcal{A}}=p_1n_1+p_2n_2+p_3n_3=0,5\cdot 2+0,3\cdot 2+0,2\cdot 2=2,0,$  povprečna dolžina kodnih zamenjav koda  $\mathcal{B}_1$  je  $\overline{n}_{\mathcal{B}_1}=1,2,$  povprečne dolžine kodnih zamenjav kodov  $\mathcal{B}_2,\mathcal{C}$  in  $\mathcal{D}$  pa:  $\overline{n}_{\mathcal{B}_2}=\overline{n}_{\mathcal{C}}=\overline{n}_{\mathcal{D}}=1,5.$ 

S stališča gospodarnosti lahko trdimo, da je enakomerni kod  $\mathcal{A}$  najslabši, neenakomerni kod  $\mathcal{B}_1$  pa najboljši, ker omogoča kodiranje sporočil z najmanjšo povprečno dolžino kodnih zamenjav.

Vendar moramo nalogo iskanja gospodarnih kodov omejiti na tiste neenakomerne kode, ki jih je možno enolično dekodirati.

#### Enakomerni kodi

Enakomerni kodi so praviloma negospodarni kodi vira (glej primer 5.5).

Vendar se zaradi preprostih postopkov kodiranja in dekodiranja ter njihove neodvisnosti od statističnih lastnosti vira v računalniških sistemih za obdelavo in prenos informacije za prilagoditev vira tehničnim zahtevam kanala uporabljajo skoraj izključno enakomerni kodi.

Gospodarno kodiranje vira, ki ga omogočajo neenakomerni kodi, se nato udejanji v procesu obdelave informacije nad enakomernimi kodi danega vira informacije.

#### Kod ASCII

Kod ASCII je enakomerni kod (A, B, f), kjer so:

- A množica alfanumeričnih znakov z močjo 128,
- ▶ B abeceda koda {0,1} in
- ▶ f preslikava, ki je standardizirana in podana tabelarično. (Glej tabelo 9.2.1 v Dodatku učbenika *Informacija in kodi*.)

V ameriških stadardih ANSI (American National Standard Institution) je kod dobil ime ASCII (American Standard Code for Information Interchange).

Vse kodne zamenjave koda ASCII so dolge m=7 (dvojiških) znakov. Navadno se kodnim zamenjavam doda še en (osmi) znak, ki služi za preverjanje sodosti, to je za odkrivanje lihega števila napak na kodnih zamenjavah pri njihovem prenosu po kanalu.

## Drugi standardni enakomerni kodi

Danes obstaja vrsta standardnih enakomernih in neenakomernih kodov (kodnih tabel), ki so v glavnem izšli iz koda ASCII in so bili razviti za kodiranje znakov različnih jezikov in jezikovnih skupin.

- ▶ Mednarodna organizacija ISO je določila vrsto kodov ISO-8859-1, ISO-8859-2, ...
- ▶ Podjetje IBM je v sodelovanju z ANSI določilo kode CP850, CP852, CP855, ...
- ▶ Podjetje Microsoft je določilo svoje kode Windows-1250, Windows-1251, ...
- Mednarodni konzorcij UNICODE je v sodelovanju z IEEE določil v zadnjem času najbolj pogosto uporabljene univerzalne mednarodne kode UTF-8, UTF-16, UTF-32.

Za kodiranje znakov abecede slovenščine pridejo v poštev kodne tabele CP852, Windows-1250, ISO-8859-2, UTF-8, UTF-16, UTF-32.

#### Neenakomerni kodi

Gospodarne kode iščemo med neenakomernimi kodi, ki jih lahko enolično dekodiramo, zato najprej raziščimo pogoje, pod katerimi lahko sestavimo enolične neenakomerne kode.

Temeljni rezultat povzemata Kraftov in McMillanov izrek.

IZREK 5.1 (Kraftov izrek) Če neenakomerni kod (A, B, f) z dolžinami kodnih zamenjav  $n_1, n_2, ..., n_a$  zadošča neenačbi

$$\sum_{i=1}^{a} b^{-n_i} \le 1, \qquad (\textit{neenačba Krafta in McMillana}) \qquad (1)$$

obstaja trenutni kod z dolžinami kodnih zamenjav  $n_1, n_2, ..., n_a$ .

Dokaz: Glej učbenik Informacija in kodi, str. 71.

#### Neenakomerni kodi - neenačba Krafta in McMillana

IZREK 5.2 (McMillanov izrek) Za vsak kod (A, B, f) z dolžinami kodnih zamenjav  $n_1, ..., n_a$ , ki omogoča enolično dekodiranje, velja

$$\sum_{i=1}^{a} b^{-n_i} \leq 1.$$
 (neenačba Krafta in McMillana)

Dokaz: Glej učbenik Informacija in kodi, str. 72.

Oglejmo si, ali kodi iz primera 5.3 zadoščajo neenačbi Krafta in McMillana.

## Neenakomerni kodi - primer

#### Primer 5.6

Kodi iz primera 5.3:

Α	$kod\ \mathcal{A}$	kod $\mathcal{B}_1$	kod $\mathcal{B}_2$	$kod\;\mathcal{C}$	$kod\; \mathcal{D}$
<i>x</i> <sub>1</sub>	00	0	0	0	0
<i>x</i> <sub>2</sub>	01	1	01	10	01
<i>X</i> 3	10	01	10	11	11

Kod  $\mathcal{B}_1$  ne zadošča neenačbi Krafta in McMillana, ker

$$\sum_{i=1}^{a} b^{-n_i} = 2^{-1} + 2^{-1} + 2^{-2} = \frac{5}{4} > 1,$$

zato ne moremo sestaviti enoličnega neenakomernega (netrenutnega ali trenutnega) koda z dolžinami kodnih zamenjav:  $n_1 = 1$ ,  $n_2 = 1$  in  $n_3 = 2$ .

#### Neenakomerni kodi

Kod  $\mathcal{B}_2$  zadošča neenačbi Krafta in McMillana, ker

$$\sum_{i=1}^{a} b^{-n_i} = 2^{-1} + 2^{-2} + 2^{-2} = 1 \le 1,$$

zato lahko sestavimo enoličen neenakomeren kod z dolžinami kodnih zamenjav:  $n_1=1$ ,  $n_2=2$  in  $n_3=2$  (glej koda  $\mathcal D$  in  $\mathcal C$  iz primera 5.3).

Kod $\mathcal C$  je trenuten kod, zato po pričakovanju zadošča neenačbi Krafta in McMillana, ki je enaka gornji neenačbi

Kod  $\mathcal{D}$  je neenakomeren kod, ki ga je možno enolično dekodirati, vendar ni trenuten. Ker zadošča neenačbi Krafta in McMillana (enaka kot zgoraj) lahko sestavimo trenuten kod z istimi dolžinami kodnih zamenjav (glej kod  $\mathcal{C}$  iz primera 5.3).

Raziščimo pogoje, pod katerimi je možno sestaviti enolične neenakomerne kode z najmanjšo povprečno dolžino kodnih zamenjav  $\overline{n}$ .

Najpomembnejši rezultat je vsebovan v izrekih 5.3 – 5.5, ki jih pripisujemo Shannonu in Fanoju.

**IZREK 5.3** Naj bo dan diskreten stacionaren vir informacije brez spomina, v katerem znak  $x_i \in A$  oddamo z verjetnostjo  $p_i \geq 0$   $(i=1,2,...,a; \sum_{i=1}^a p_i=1)$ . Tedaj obstaja neenakomerni kod (A,B,f) s povprečno dolžino kodnih zamenjav  $\overline{n}$ , ki ga je možno enolično dekodirati, in velja

$$\frac{H}{K \log_d b} \le \overline{n} < \frac{H}{K \log_d b} + 1, \tag{2}$$

kjer je

$$H = -K \sum_{i=1}^{a} p_i \log_d p_i$$

entropija diskretnega stacionarnega vira brez spomina.

Dokaz: Glej učbenik Informacija in kodi, str. 74.

Za stacionarne vire brez spomina bi v lahko v dokazu izreka 5.3 pokazali, da za vsak kod (A, B, f), ki omogoča enolično dekodiranje, velja

$$\overline{n} \geq \frac{H}{K \log_d b}.$$

 $H/(K\log_d b)$  je torej najmanjša povprečna dolžina kodnih zamenjav, ki jo dosežemo le, če lahko zapišemo verjetnosti znakov abecede vira  $p_i~(i=1,2,...,a)$  kot celoštevilčne potence osnove b.

Vendar pa se lahko spodnji meji poljubno približamo tudi, če namesto posameznih znakov kodiramo r-terice (bloke) znakov, ki jih obravnavamo kot posamezne znake hiperabecede  $A^r$ .

**IZREK 5.4** Naj bo dan diskreten stacionaren vir informacije brez spomina, v katerem znak  $x_i \in A$  oddamo z verjetnostjo  $p_i \geq 0$   $(i=1,2,...,a;\sum_{i=1}^a p_i=1)$ . Tedaj obstaja trenutni kod  $(A^r,B,f)$ , ki omogoča, da se s povprečno dolžino kodnih zamenjav  $\overline{n}$  poljubno približamo spodnji meji

$$\frac{H}{K \log_d b},\tag{3}$$

kjer je H entropija diskretnega stacionarnega vira informacije brez spomina.

Dokaz: Glej učbenik Informacija in kodi, str. 75.

Iz dokaza izreka 5.4 sledi, da se gospodarnost koda s podaljševanjem blokov znakov, ki jim prirejamo kodne zamenjave<sup>4</sup>, povečuje.

 $<sup>^4</sup>$ Z večanjem r se eksponentno podaljšujeta tudi časa, ki sta potrebna za kodiranje in dekodiranje sporočil, kar je seveda slabo.

Rezultat izreka 5.4 lahko posplošimo, da velja za vsak diskreten stacionaren vir informacije.

IZREK 5.5 (Shannonov izrek o gospodarnem kodiranju) Naj bo dan diskreten stacionaren vir informacije, v katerem znak  $x_i \in A$  oddamo z verjetnostjo  $p_i \geq 0$  (i=1,2,...,a;  $\sum_{i=1}^a p_i=1$ ). Tedaj obstaja trenutni kod ( $A^r, B, f$ ), ki omogoča, da se povprečna dolžina kodnih zamenjav  $\overline{n}$  poljubno približa meji

$$\frac{H}{K \log_d b},\tag{4}$$

kjer je H entropija diskretnega stacionarnega vira informacije.

Dokaz: Glej učbenik *Informacija in kodi*, str. 76.

Za trenutni kod s povprečno dolžino kodnih zamenjav, vsebovano v intervalu:

$$\frac{H}{K \log_d b} \leq \overline{n} < \frac{H}{K \log_d b} + 1,$$

$$\frac{H}{K \log_d b} \leq \frac{\overline{n}_r}{r} < \frac{H}{K \log_d b} + \frac{1}{r}$$

oziroma

$$\frac{H(X_1,...,X_r)}{r}\frac{1}{K\log_d b} \leq \overline{n} < \frac{H(X_1,...,X_r)}{r}\frac{1}{K\log_d b} + \frac{1}{r},$$

pravimo, da je **gospodaren**, za gospodarni kod s povprečno dolžino kodnih zamenjav, ki je najbližja vrednosti  $H/(K \log_d b)$  pa pravimo, da je **(globalno) optimalen**.

Za iskanje gospodarnih kodov je pomembna naslednja posledica izrekov 5.1-5.5, kakor tudi trditvi 5.1 in 5.2, ki govorita o lastnostih gospodarnih kodov.

**POSLEDICA 5.1** Če je kod (A,B,f) gospodaren kod v razredu enoličnih neenakomernih kodov s fiksiranima a in b, to je, če je  $\overline{n}(f) \leq \overline{n}(g)$ , kjer je  $\overline{n}(g)$  povprečna dolžina kodnih zamenjav v kateremkoli kodu (A,B,g) iz istega razreda, potem v istem razredu obstaja trenutni kod (A,B,h), za katerega velja

$$\overline{n}(h) = \overline{n}(f). \tag{5}$$

Dokaz: Glej učbenik Informacija in kodi, str. 77.

Vidimo, da se lahko pri iskanju gospodarnih kodov omejimo le na množico *trenutnih* kodov, to je kodov z dolžinami kodnih zamenjav, ki zadoščajo neenačbi Krafta in McMillana.

**TRDITEV 5.1** Če je kod (A, B, f) gospodaren kod, potem velja :

$$p_j>p_k\Longrightarrow n_j\leq n_k, \qquad j\neq k, \quad j,k\in\{1,2,...,a\}.$$

Ta trditev pravi, da v gospodarnem kodu znakom z večjo verjetnostjo pripisujemo krajše kodne zamenjave.

Dokaz: Glej učbenik *Informacija in kodi*, str. 77.

**TRDITEV 5.2** Obstaja takšen gospodaren trenutni kod (A, B, f), da imata kodni zamenjavi  $f(x_{a-1})$  in  $f(x_a)$  enaki dolžini  $n_{a-1} = n_a$ , razlikujeta pa se le v zadnjem znaku.

Dokaz: Glej učbenik *Informacija in kodi*, str. 78.

V nadaljevanju si oglejmo tri postopke gradnje gospodarnih kodov  $(A, \{0,1\}, f)$ .

### Huffmanov kod

Huffmanov algoritem omogoča sestavljanje gospodarnega trenutnega koda za podani množici  $A = \{x_1, x_2, ..., x_a\}$  in  $B = \{0, 1\}$  (a > 2) in podano porazdelitev verjetnosti  $p_1, p_2, ..., p_a$   $(p_i \ge 0, \sum_{i=1}^a p_i = 1)$ .

#### Začetek postopka

- 1. korak Naredi:
  - a) postavi  $A_0 \leftarrow A$ ,
  - b) znake v  $A_0$  uredi tako, da je  $p_1 \geq p_2 \geq \ldots \geq p_a$ ,
  - c) znaku  $x_{a-1} \in A_0$  pripiši znak  $0 \in B$ , znaku  $x_a \in A_0$  pa znak  $1 \in B$ .

#### Huffmanov kod

#### 2. korak

 $za j \leftarrow 1 do a - 2 naredi:$ 

- a) sestavi množico  $A_j$  tako, da združiš zadnja znaka množice  $A_{j-1}$  v en znak in mu pripiši verjetnost, ki jo dobimo kot vsoto verjetnosti združenih znakov. Množica  $A_j$  ima  $a_j = a j$  znakov,
- b) množico  $A_j$  uredi tako, da je  $p_1 \ge p_2 \ge \ldots \ge p_{a_j}$ ,
- c) znaku  $x_{a_j-1} \in A_j$  pripiši znak  $0 \in B$ , znaku  $x_{a_i} \in A_i$  pa znak  $1 \in B$ .

#### konec-za

3. korak Kodno zamenjavo za znak abecede vira  $x_i$  sestavimo tako, da vse znake abecede B, ki so se pojavljali z indeksom i, jemljemo po vrsti od konca proti začetku postopka.

Konec postopka

#### Primer 5.7

Vzemimo, da je dan vir brez spomina, ki oddaja znake iz abecede  $A = \{x_1, x_2, x_3\}; \ a = 3.$ 

Vzemimo naprej, da so verjetnosti oddaje znakov iz A enake  $P(x_1) = 0.60, P(x_2) = 0.30$  in  $P(x_3) = 0.10$  ter abeceda koda  $B = \{0, 1\}; \ b = 2.$  Poišči Huffmanov kod znakov iz A.

Spodnja tabela vsebuje a) ponazoritev poteka Huffmanovega algoritma in b) tabelo Huffmanovega koda (znaki iz abecede vira in njihove kodne zamenjave).

<i>x</i> <sub>1</sub>	<i>x</i> <sub>2</sub>	<i>X</i> <sub>3</sub>		
0,6	0,3	0,1		
	0	1		
<i>x</i> <sub>1</sub>	X <sub>23</sub>			
0,6	0,4			
0		1		

$f(x_i)$
0
10
11

a)

b)

Povprečna dolžina kodnih zamenjav  $\overline{n}$ , entropija vira brez spomina H in uspešnost koda  $\eta$ , ki jo definiramo kot razmerje med entropijo vira in povprečno dolžino kodnih zamenjav, so:

$$\overline{n} = \sum_{i=1}^{3} p_i n_i = 1,40 \text{ znaka},$$
 $H = -\sum_{i=1}^{a} p_i \log_2 p_i = 1,295 \text{ bitov in}$ 
 $\eta = H/\overline{n} \cdot 100\% = 92,5 \%.$ 

Huffmanov kod dekodiramo s pomočjo kodne tabele, ki jo (obvezno) *pripnemo* nizu kodnih zamenjav danega sporočila.

#### Primer 5 8

Oglejmo si, kako dekodiramo niz kodnih zamenjav 11100010011 s pomočjo tabele Huffmanovega koda iz primera 5.7.

- Dekodiranje začnemo takoj po sprejetju prvega znaka kodiranega sporočila.
- Preverimo, če vsebuje kodna tabela (b) zamenjavo 1.
- Ker je ne vsebuje, počakamo na sprejem drugega znaka.
- Preverimo, če vsebuje kodna tabela zamenjavo 11.
- ightharpoonup Ugotovimo, da je niz 11 kodna zamenjava znaka abecede vira  $x_3$ .
- Počakamo na sprejem tretjega znaka. Ker kodna tabela ne vsebuje zamenjave 1, počakamo na sprejem četrtega znaka. Preverimo, če vsebuje kodna tabela zamenjavo 10.
- ▶ Ugotovimo, da je niz 10 kodna zamenjava znaka abecede vira  $x_2$ , itn. dokler ne dekodiramo tudi zadnje kodne zamenjave sprejetega sporočila.

Rezultat dekodiranja niza kodnih zamenjav 11100010011 je niz znakov abecede vira  $x_3x_2x_1x_1x_2x_1x_3$ .

#### Huffmanov kod

Gospodarnost koda povečamo, če namesto posameznih znakov s Huffmanovim algoritmom kodiramo *r*-terice znakov v sporočilu.

Pri tem, če dolžina sporočila, ki ga kodiramo, ni celi večkratnik števila r, na koncu sporočila pripnemo med 1 in r-1 'lažnih' znakov<sup>5</sup>.

<sup>&</sup>lt;sup>5</sup>Znakov z verjetnostjo oddaje 0. V angleški literaturi: *dummy*.

#### Primer 5.9

Vzemimo, da sta dana vir brez spomina iz primera 5.7 ter abeceda koda  $B = \{0, 1\}$ . Poišči Huffmanov kod znakov iz  $A^2$ .

Ker bomo kodirali pare znakov iz A, tvorimo množici

$$A^{2} = \{x_{1}^{*} = x_{1}x_{1}, x_{2}^{*} = x_{1}x_{2}, x_{3}^{*} = x_{2}x_{1}, x_{4}^{*} = x_{2}x_{2}, x_{5}^{*} = x_{1}x_{3}, x_{6}^{*} = x_{3}x_{1}, x_{7}^{*} = x_{2}x_{3}, x_{8}^{*} = x_{3}x_{2}, x_{9}^{*} = x_{3}x_{3}\} \text{ ter}$$

$$P_{2} = \{ P(x_{1}^{*}) = P(x_{1}x_{1}) = P(x_{1})P(x_{1}) = 0.36, \ P(x_{2}^{*}) = 0.18,$$

$$P(x_{3}^{*}) = 0.18, \ P(x_{4}^{*}) = 0.09, \ P(x_{5}^{*}) = 0.06, \ P(x_{6}^{*}) = 0.06,$$

$$P(x_{7}^{*}) = 0.03, \ P(x_{8}^{*}) = 0.03, \ P(x_{9}^{*}) = 0.01 \}.$$

× <sub>1</sub> *	x <sub>2</sub> *	χ <sub>3</sub> *	x <sub>4</sub> * 0,09	× <sub>5</sub> * 0,06	×* 0,06	×*	0,03	0,01
0,36	0,18	0,18	0,09	0,06	0,06	0,03	0,03	1
x <sub>1</sub> *	x <sub>2</sub> * 0,18	x <sub>3</sub> * 0,18	x <sub>4</sub> * 0,09	× <sub>5</sub>	×6 0,06	×,	89 04	x <sub>7</sub> * 0,03
0,36	0,18	0,18	0,09	0,06	0,06			0,03
x <sub>1</sub> *	x <sub>2</sub> *	Y.*	Y*		Y*	ļ ,	)   <u>v*</u>	Y*
0,36	0,18	0,18	0,09		× <del>*</del> 789 0,07		0,06	×6 0,06
							0	1
× <sub>1</sub> * 0,36	x <sub>2</sub> * 0,18	** 0,18	x <sub>56</sub> x <sub>4</sub> x <sub>789</sub> 0,12         0,09         0,07					
0,50	0,10	0,10	0,12 0,09 0,07					
x <sub>1</sub> *	$x_2^*$	×**	$\begin{array}{c cccc} x_{4789}^{*} & x_{56}^{*} \\ 0,16 & 0,12 \end{array}$				* 5 6	
0,36	0,18	0,18	0,16 0,12				12	
x <sub>1</sub> *			×45.				x *	×3
0,36		0,28 0,18 0,1					0,18	
x <sub>1</sub> *	0 1					1		
0,36	x***23     x***456789       0,36     0,28							
,	0 1							
			×2*34!	5 <b>6789</b> 64				0,36
				0				0,36

×;*	$f(x_i^*)$	
×*	1	
×2	000	
x *	001	
×4*	0100	
× 5	0110	
× *	0111	
×Ŷ	01011	
×*	010100	
×ŝ	010101	

a)

b)

Povprečna dolžina kodnih zamenjav iz tabele b)  $\overline{n}_2$  in uspešnost koda  $\eta$  sta:

$$\overline{n}_2 = \sum_{i=1}^9 P(x_i^*) \cdot n_i = 2,67$$
 znaka in  $\eta = H/\overline{n} \cdot 100\% = 2H/\overline{n}_2 \cdot 100\% = 97,0\%$ .

Ker je uspešnost Huffmanovega koda iz primera 5.7 bila 92,5 %, sledi, da je kodiranje parov znakov iz abecede vira povečalo uspešnost Huffmanovega koda za 4.5 %.

Opazimo, da je razsežnost tabele Huffmanovega koda parov znakov iz abecede A enaka  $a^r=3^2$ , torej, da eksponentno narašča s podaljševanjem blokov sporočila, ki jih kodiramo.

#### Aritmetični kod

Tako kot Huffmanov algoritem, tudi algoritem aritmetičnega kodiranja temelji na poznavanju verjetnosti *r*-teric (blokov), ki jih kodiramo, vendar omogoča dekodiranje koda danega sporočila brez kodne tabele.

Zadošča, da poznamo abecedo vira informacije in verjetnosti oddaje posameznih znakov.

Tudi če dolžina sporočila, ki ga kodiramo, ni celi večkratnik dolžine bloka, sporočilu ni potrebno pripenjati *lažnih znakov*, ker dolžina blokov, med kodiranjem sporočila, ni nujno stalna.

#### Aritmetični kod

Zasnovo aritmetičnega kodiranja lahko strnemo v naslednje korake:

a) Interval realnih števil [0,1) razdelimo na a (pod)intervalov tako, da priredimo vsakemu znaku  $x_i$  iz abecede vira A interval  $\mathcal{R}(x_i) = [s_i, z_i)$ , ki je sorazmeren z njegovo verjetnostjo oddaje. Pri tem velja:  $s_1 = 0$ ,  $z_a = 1$ ,  $s_i = z_{i-1}$  za  $1 < i \le a$  ter  $\mathcal{R}(x_i) \cap \mathcal{R}(x_j) = \emptyset$ , če  $x_i \ne x_j$ . Torej:

$$\mathcal{R}(x_1) = [0, z_1),$$
  
 $\mathcal{R}(x_2) = [s_2 = z_1, z_2),$ 

in tako naprej do

$$\mathcal{R}(x_a) = [s_a = z_{a-1}, 1).$$

### Aritmetični kod

b) Kodiranje r-terice (bloka) znakov  $\mathbf{x} = x_1 x_2 \cdots x_r$  temelji na r-kratni preslikavi intervala

$$[s,z) \longrightarrow [s',z'),$$
 (6)

kjer sta:

$$s' = s + (z - s) \cdot s_j,$$

in

$$z'=s+(z-s)\cdot z_j.$$

c) Aritmetični kod bloka znakov x je poljubno realno število, ki leži na r-tem intervalu [s', z').

# Aritmetični kod - algoritem

#### VHOD:

- 1. abeceda vira informacije  $A = \{x_1, ..., x_i, ..., x_a\}$ ,
- 2. porazdelitev verjetnosti  $P = (p_1, ..., p_i, ..., p_a)$ , kjer je  $p_i = P(x_i)$ ,
- 3. r-terica (blok) znakov x =  $x_1 \cdots x_j \cdots x_r$  iz abecede vira A, ki ga želimo gospodarno kodirati. Znak  $x_r \in A$  je poseben znak (PZ), ki označuje konec bloka x, na primer pika na koncu stavka<sup>6</sup>.

#### IZHOD:

Kodna zamenjava f(x) bloka x, to je niz znakov iz abecede koda  $B = \{0, 1\}.$ 

 $<sup>^{6}</sup>$ Če kodiramo bloke fiksne dolžine, znak  $\mathrm{PZ}$ , ki označuje konec bloka, ni potreben.

## Aritmetični kod - algoritem

#### Začetek postopka

- 1. korak Priredi vsakemu znaku  $x_i \in A$  interval realnih števil  $\mathcal{R}(x_i) = [s_i, z_i)$ , ki je sorazmeren verjetnosti znaka  $p_i$  tako, da velja:  $s_1 = 0$ ,  $z_a = 1$ ,  $s_i = z_{i-1}$  za  $1 < i \le a$  ter  $\mathcal{R}(x_i) \cap \mathcal{R}(x_j) = \emptyset$ , če  $x_i \ne x_j$ .
- **2.** korak Postavi:  $s \leftarrow 0$ ,  $z \leftarrow 1$  in  $j \leftarrow 1$
- **3.** korak Dokler  $j \neq r$ , ponavljaj:
  - a) za znak  $x_j$  iz bloka znakov x izračunaj: a1)  $s \leftarrow s + (z - s) \cdot s_j$ a2)  $z \leftarrow s + (z - s) \cdot z_j$
  - b)  $j \leftarrow j + 1$
- 4. korak Zapiši s in z v dvojiškem številskem sistemu
- 5. korak Če je  $(s)_2 = 0$ ,  $a_1 a_2 ... a_{t-1} 0...$  in  $(z)_2 = 0$ ,  $a_1 a_2 ... a_{t-1} 1...$ , potem je niz dvojiških znakov  $a_1 a_2 ... a_{t-1} 1$  kodna zamenjava f(x) r-terice znakov  $x \in A^r$ .

Konec postopka

### Aritmetični kod - primer

#### Primer 5 10

Dani sta abeceda vira

$$A = \{x_1, x_2, x_3, x_4 = PZ\}, \quad a = 4,$$

in verjetnosti znakov v sporočilu:

$$P(x_1) = 0.5, P(x_2) = 0.1, P(x_3) = 0.3, P(x_4) = 0.1.$$

Vzemimo, da je r-terica znakov, ki jo želimo gospodarno zakodirati z aritmetičnim kodom, enaka

$$x_1x_2x_1x_3\mathrm{PZ}.$$

Interval realnih števil [0,1) najprej razdelimo na a=4 podintervale:

$$\mathcal{R}(x_1) = [0, 0.5), \ \mathcal{R}(x_2) = [0.5, 0.6), \ \mathcal{R}(x_3) = [0.6, 0.9), \ \mathcal{R}(x_4) = [0.9, 1),$$

## Aritmetični kod - primer

nato zakodiramo dani blok znakov  $x_1x_2x_1x_3$ PZ z r=5-imi preslikavami (6):

$$[0,1) \xrightarrow{x_1} [s' = 0 + (1-0) \cdot 0 = 0, \ z' = 0 + (1-0) \cdot 0,5 = 0,5) \xrightarrow{x_2}$$

$$\underbrace{x_2}_{} [0,25, \ 0,3) \xrightarrow{x_1} [0,25, \ 0,275) \xrightarrow{x_3} [0,265, \ 0,2725) \xrightarrow{PZ} [0,27175, \ 0,2725).$$

Ker sta 
$$(0,27175)_{10} = (0,0100010110...)_2^7$$
 in  $(0,2725)_{10} = (0,0100010111...)_2$ , je aritmetični kod danega sporočila 0100010111.

<sup>&</sup>lt;sup>7</sup>Pretvorbo necelega desetiškega števila 0,27175 v dvojiško število ponazarja naslednja razpredelnica:

# Aritmetični kod - dekodiranje

Dekodiranje aritmetičnega koda temelji na večkratni preslikavi dvojiškega števila

$$v = 0, a_1 a_2 \dots a_{t-1} 1 \longrightarrow v',$$

kjer je

$$v' = \frac{v - s_j}{z_j - s_j}. (7)$$

Za dan v in za vsak novi v' iščemo interval  $\mathcal{R}(x_j)$ , v katerem se ta nahaja, ter ta del sporočila dekodiramo z znakom  $x_j \in A$ .

# Aritmetični kod - algoritem dekodiranja

#### VHOD:

- 1. abeceda vira informacije  $A = \{x_1, ..., x_i, ..., x_a\}$ ,
- 2. porazdelitev verjetnosti  $P = (p_1, ..., p_i, ..., p_a)$ , kjer je  $p_i = P(x_i)$ ,
- 3. kodna zamenjava f(x) bloka znakov x, to je niz znakov  $a_1a_2...a_{t-1}1$  iz abecede koda  $B=\{0,1\}$ .

**IZHOD**: r-terica (blok) znakov iz abecede vira  $x = x_1 \cdots x_j \cdots x_r$ , kjer sta  $x_j \in A$  (j = 1, 2, ..., r) in  $x_r = PZ$ .

# Aritmetični kod - algoritem dekodiranja

#### Začetek postopka

- 1. korak Priredi vsakemu znaku  $x_i \in A$  interval realnih števil  $\mathcal{R}(x_i) = [s_i, z_i)$ , ki je sorazmeren verjetnosti znaka  $p_i$  tako, da velja:  $s_1 = 0$ ,  $z_a = 1$ ,  $s_i = z_{i-1}$  za  $1 < i \le a$  ter  $\mathcal{R}(x_i) \cap \mathcal{R}(x_j) = \emptyset$ , če  $x_i \ne x_j$ .
- 2. korak Niz dvojiških znakov  $a_1a_2...a_{t-1}1$  obravnavaj kot dvojiško število  $v=0, a_1a_2...a_{t-1}10\cdots 0$  in ga zapiši v desetiškem številskem sistemu.
- **3.** korak Postavi  $j \leftarrow 1$ .
- **4.** korak Dokler  $x_i \neq PZ$ , ponavljaj:
  - a) najdi znak  $x_j \in A$  tako, da bo  $v \in \mathcal{R}(x_j)$ ,
  - b) vpiši znak  $x_j$  v niz x,
  - c) izračunaj  $v \leftarrow (v s_i)/(z_i s_i)$ ,
  - d)  $j \leftarrow j + 1$

## Aritmetični kod - primer dekodiranja

#### Primer 5 11

Dani sta abeceda vira

$$A = \{x_1, x_2, x_3, x_4 = PZ\}, \quad a = 4,$$

in verjetnosti znakov v bloku znakov:

$$P(x_1) = 0.5, P(x_2) = 0.1, P(x_3) = 0.3, P(x_4) = 0.1.$$

Interval realnih števil [0,1) razdelimo na a=4 podintervale:

$$\mathcal{R}(x_1) = [0, 0,5), \, \mathcal{R}(x_2) = [0,5, 0,6), \, \mathcal{R}(x_3) = [0,6, 0,9), \, \mathcal{R}(x_4) = [0,9, 1).$$

Vzemimo, da je kod bloka znakov x, ki ga želimo dekodirati, enak 0100010111. Tega zapišemo kot

$$\nu = (0.01000101110 \cdots 0)_2 = 2^{-2} + 2^{-6} + 2^{-8} + 2^{-9} + 2^{-10} = (0.2724609375)_{10}.$$

# Aritmetični kod - primer dekodiranja

Vrednost v = 0,2724609375 dekodiramo kot  $x_1$ , ker je  $0,2724609375 \in \mathcal{R}(x_1) = [0, 0,5)$ .

Iz izraza (7) izračunamo

$$v' = \frac{0,2724609375 - 0}{0,5 - 0} = 0,544921875.$$

Vrednost v' = 0.544921875 dekodiramo kot  $x_2$ , ker je  $0.544921875 \in \mathcal{R}(x_2) = [0.5, 0.6)$ .

Postavimo v=0,544921875 in iz izraza (7) izračunamo v'=0,44921875. Vrednost v'=0,44921875 dekodiramo kot  $x_1$ , ker je  $0,44921875 \in \mathcal{R}(x_1)=[0,\,0,5)$ .

# Aritmetični kod - primer dekodiranja

Postavimo v=0,44921875 in iz izraza (7) izračunamo v'=0,8984375. Vrednost v'=0,8984375 dekodiramo kot  $x_3$ , ker je  $0,8984375 \in \mathcal{R}(x_3)=[0,6,0,9)$ .

Postavimo v=0.8984375 in iz izraza (7) izračunamo v'=0.9947916667. Vrednost v'=0.9947916667 dekodiramo kot PZ, ker je  $0.9947916667 \in \mathcal{R}(x_4=\mathrm{PZ})=[0.9,\ 1)$ .

Ko dekodiramo znak PZ, ustavimo postopek dekodiranja. Torej, kod 1011101001 dekodiramo kot  $x_1x_2x_1x_3PZ$ .

# Kod Lempela, Ziva in Welcha (LZW)

Videli smo, da zahtevata Huffmanov in aritmetični kod vnaprejšnje poznavanje porazdelitve verjetnosti znakov v sporočilu, ki ga kodiramo.

Če te ne poznamo, lahko gospodarno kodiramo sporočila tako, da sproti ugotavljamo krajše nize znakov, ki se v sporočilu ponavljajo, ter jih nato učinkovito zakodiramo.

#### Primer 5.12

Vzemimo niz dvojiških znakov

1011010100010 · · ·

Od začetka proti koncu niza iščemo najkrajše podnize, ki se v nizu prvič pojavijo. Dobimo

$$1, 0, 11, 01, 010, 00, 10 \cdots$$

# Kod LZW - algoritem kodiranja

Algoritem gospodarnega kodiranja LZW temelji na ugotavljanju podnizov danega niza (na primer besedila, zakodiranega s kodom ASCII).

#### TABELE:

- ST Tabela, ki hrani sporočilo (besedilo), ki ga želimo kodirati,
- KT tabela s kodnimi zamenjavami sporočila iz tabele ST,
- PT pomožna tabela slovar, ki hrani na mestih med 0 in 255 znake abecede vira, od mesta 256 naprej pa različne nize znakov abecede vira.

VHOD: Tabela ST.

IZHOD: Tabela KT.

#### Kod I 7W

- 1. korak Preberi prvi znak s iz tabele ST.
- 2. korak Dokler ne prideš do zadnjega znaka v tabeli ST, ponavljaj:
  - a) t je naslednji znak v tabeli ST
  - b) spni oba znaka (niza) v niz  $u \leftarrow s || t$
  - c)  $\bar{\mathbf{c}}\mathbf{e}$  je u v slovarju PT,

#### potem

c1) postavi  $s \leftarrow u$ ,

#### sicer:

- c2) prenesi naslov, ki ga ima s v slovarju *PT*, v tabelo *KT*,
- c3) vpiši *u* v slovar *PT* na prvo prosto mesto po naslovu 255.
- c4) postavi  $s \leftarrow t$ .

#### konec-ce

3. korak Prenesi naslov, ki ga ima s v slovarju PT, v tabelo KT.

#### Primer 5 13

Vzemimo, da imamo v tabeli ST sporočilo TRALALALA.

Tabela kodnih zamenjav KT je na začetku prazna.

Vzemimo, da so v slovarju *PT* na mestih med 0 in 255 zapisani znaki abecede vira tako, da jim mesto določa njihov kod ASCII.

Na primer, črka A je zapisana na 65-em mestu, ker je kod ASCII črke A enak  $(65)_{10} = (01000001)_2$  (glej tabelo ASCII znakov).

#### Postopek kodiranja:

Preberemo prvi znak sporočila iz tabele ST in postavimo s=T. Nato preberemo še drugi znak ter postavimo t=R. Spnemo znaka s in t. Dobimo u=TR, česar ni v slovarju PT.

Zato prenesemo naslov znaka T(=s) iz slovarja PT, to je  $(84)_{10}$  oziroma  $(01010100)_2$ , v tabelo KT, njegovo kodno zamenjavo, to je niz znakov TR(=u), pa vpišemo v slovar PT na mesto 256.

Postavimo s=t=R in nadaljujemo s tretjim znakom sporočila t=A. Sledi u=RA, česar ni v slovarju PT. Zato vpišemo RA v slovar PT na mesto 257.

Naslov znaka R v slovarju PT je njegova kodna zamenjava itn.

Vsakokrat, ko se pojavi v tabeli znak PZ (=poseben znak), to pomeni, da se bo povečala razsežnost kodnih zamenjav za en dvojiški znak od znaka PZ naprej.

Znakom PZ navadno prirejamo desetiške vrednosti 255,511,1023,...

Tabela ponazarja postopek kodiranja in dograjevanja slovarja PT.

Sporočilo <i>ST</i>							
TRALALALA							
S	t	и	Kod <i>KT</i>		Kod KT Slova		ar <i>PT</i>
			$(\cdot)_{10}$	$(\cdot)_2$	Vpis	Mesto	
T	R	TR	84	01010100	TR	256	
R	Α	RA	82	01010100	RA	257	
Α	L	AL	65	01000001	AL	258	
L	Α	LA	76	01001011	LA	259	
Α	L	AL					
			PZ	11111111			
AL	Α	ALA	258	100000010	ALA	260	
Α	L	AL					
AL	Α	ALA					
ALA	L	ALAL	260		ALAL	261	
L	Α	LA		100000100			
LA		LA	259	100000011			

Ugotovimo, da smo sporočilo, ki je bilo zakodirano z ASCII kodom z 88-imi dvojiškimi znaki, gospodarno zakodirali s kodom LZW s 67-imi dvojiškimi znaki:

Po končanem kodiranju slovarja PT ne potrebujemo več.

Zapomniti si moramo le naslove posameznih znakov iz abecede vira (prvih 256 mest).

Zato ponavadi znake abecede vira zakodiramo s katerim izmed standardiziranih kodov z  $m \le 8$  (v našem primeru smo uporabili kod ASCII), kod znaka pa uporabimo tudi kot njegov naslov v slovarju.

## Kod LZW - algoritem dekodiranja

Algoritem za dekodiranje mora poleg dekodiranja dograjevati slovar *PT*, prav tako kot v primeru kodiranja.

VHOD: Tabela KT.

IZHOD: Tabela ST.

#### Začetek postopka

- korak Preberi kod c iz vhodne tabele KT (tabela s kodiranim sporočilom).
- 2. korak V izhodno tabelo *ST* (tabela z dekodiranim sporočilom) vpiši niz znakov *s*, ki je v slovarju *PT* vpisan na mestu *c*.
- 3. korak V slovar PT vpiši niz s||t, kjer je t prvi znak naslednjega niza s.

Konec postopka

## Kod LZW - algoritem dekodiranja

Opisani algoritem ne more dekodirati niza znakov sporočila oblike t||z||t, kjer je t poljubni znak, z pa poljubni niz znakov.

Problem rešimo tako, da:

- a) vzamemo zadnji niz, ki smo ga dekodirali (vpisali v tabelo ST), to je niz oblike  $t\|z$ ,
- b) na njegov konec pripnemo prvi znak niza t (dobimo  $t\|z\|t$ ) in ga
- c) vpišemo na naslednje prazno mesto v slovar PT.

#### Primer 5 14

Vzemimo, da želimo dekodirati niz kodnih zamenjav

84 82 65 76 PZ 258 260 259.

Mesta v slovarju med 0 in 255 so znaki, ki se lahko pojavijo v sporočilu. Znak PZ tolmačimo, kot je bilo opisano.

Kod	Sporočilo	Slovar <i>PT</i>		
KT	ST	Vpis	Mesto	
84	T			
82	R	TR	256	
65	Α	RA	257	
76	L	AL	258	
258	AL	LA	259	
260		ALA	260	
	ALA			
259	LA	ALAL	261	

## Kod LZW - algoritem dekodiranja

Na sporno situacijo naletimo pri dekodiranju kodne zamenjave 260, ker je v trenutku dekodiranja mesto 260 v slovarju *PT* prazno (brez vpisa).

Desetiški kod LZW 84 82 65 76 PZ 258 260 259. smo dekodirali kot sporočilo TRALALALALA.

Algoritem LZW lahko na različne načine kombiniramo s Huffmanovim algoritmom in algoritmom aritmetičnega koda, na primer s kodiranjem kodnih zamenjav algoritma LZW z aritmetičnim kodom ipd.

Oglejmo si kako učinkoviti so nekateri programski paketi za gospodarno kodiranje besedil, ki jih lahko najdemo na svetovnem spletu.

# Primerjava programov za gospodarno kodiranje

#### Primer 5 15

Za preizkus učinkovitosti desetih programskih paketov za gospodarno kodiranje podatkov, ki jih lahko najdemo na svetovnem spletu<sup>8</sup>, uporabimo vzorec slovenskih leposlovnih besedil, ki obsega 2721416 besed oziroma 16784110 znakov iz nabora 133-ih znakov.

Podrobnosti o uporabljenih postopkih gospodarnega kodiranja niso znani; iz časov izvajanja programov pri gospodarnem kodiranju vzorca slovenskih leposlovnih besedil sklepamo, da najboljši trije, to so Boa Constrictor, RKIVE in Ufa, ter verjetno tudi UHARC, temeljijo na zaporedni uporabi več postopkov gospodarnega kodiranja.

<sup>&</sup>lt;sup>8</sup>Programi so brezplačni ali jih je treba kupiti po določenem preizkusnem obdobju.

# Primerjava programov za gospodarno kodiranje

lme	Različica	Avtor	Čas 'stis-	n
programa			kanja' [s]	
ARJ	2.60	ARJ Software	84	3,27
ESP	1.92	GyikSoft	60	3,22
PKZIP	2.04g	PKWARE	74	3,20
RAR	2.50b3	RarSoft	138	3,09
JAR	1.02	ARJ Software	195	3,00
UHARC	0.2	Uwe Harklotz	751	2,73
Arhangel	1.38	Jurij Ljapko	188	2,52
Ufa	0.04b1	Igor Pavlov	703	2,24
RKIVE	1.92b1	Malcolm Taylor	2 148	2,23
Воа	0.58b	lan Sutton	756	2,16

Tabela: Časi 'stiskanja' in povprečne dolžine kodnih zamenjav vzorca slovenskih leposlovnih besedil z desetimi programskimi paketi za gospodarno kodiranje.

## Vprašanja

- ► Kaj je kod vira informacije?
- Zakaj kodiramo sporočila vira informacije?
- Kateri kodi vira informacije so enakomerni?
- Kateri kodi vira informacije so neenakomerni?
- Kaj pomeni, da kod vira informacije omogoca enoznačno dekodiranje?
- Za katere kode vira informacije pravimo, da so trenutni?
- Kaj je kodno drevo?
- Kako merimo optimalnost koda vira informacije?
- O čem govori Kraft-McMillanova neenakost?
- Kakšna je povprečna dolžina kodnih zamenjav optimalnih kodov vira informacije?
- ► Kaj trdi Shannon-Fanojev izrek?

