

RAZPOZNAVANJE VZORCEV

UVOD V LABORATORIJSKE
VAJE

Asistent: doc. dr. Klemen Grm

Osnovne informacije o predmetu

- Nosilec: izr. prof. dr. Simon Dobrišek, simon.dobrisek@fe.uni-lj.si
- Asistent: as. dr. Klemen Grm, klemen.grm@fe.uni-lj.si
- Tedenske obveznosti: predavanja, vaje
- Govorilne ure: ponedeljek 14h-16h, po dogovoru

Izpitni red

Točkovanje		
Obveznost	Največ	Najmanj za napredovanje
Domači nalogi	2x5	0
Obvezne vaje	3x5	8
Izbirna vaja	15	7
Pisni izpit	30	15
Ustni izpit	30	15
Skupaj	100	

Zbrane točke	Ocena
0-19	ni frekvence
20-49	5
50-59	6
60-69	7
70-79	8
80-89	9
90-100	10

Pregled laboratorijskih vaj


- Vaja 1: Izpeljava značilk
- Vaja 2: Izbira značilk
- Vaja 3: Učenje in preizkušanje razvrščevalnikov
- Izbirni projekt: poglobljena študija, implementacija in preizkus izbranega algoritma s področja razpoznavanje vzorcev

Uvod v razpoznavanje vzorcev

- Analiza podatkov
- Koncept razvrščanja
- Predstavitev podatkov z značilkami
- Eksperimentiranje s prostimi parametri

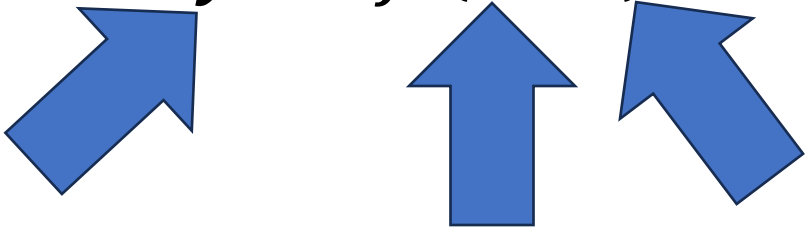
Analiza podatkov

- Format zapisa
- Pregled vzorcev
- Oznake razredov
- Statistika
 - Razredi
 - Vzorci
 - Značilke



Učenje razvrščevalnika

- Razvrščevalnik:

$$\hat{y} = f(x; \theta)$$


Napovedana
oznaka

vhodni
vzorec

parametri
razvrščevalnika

Učenje razvrščevalnika

- Postopek učenja:

$$\theta = \arg \min_{\theta} f(x, \theta) \neq y$$

- V praksi: preko posrednih kriterijskih funkcij, npr.:

$$\theta = \arg \min_{\theta} \sum_{x,y \in U} \|f(x, \theta) - y\|_p^p$$

- Različni postopki učenja – odvisno od razvrščevalnika, f

Zgled – analitična rešitev

- Metoda najmanjših kvadratov,
- Število učnih vzorcev ... N
- Število značilk ... d
- Število razredov ... r

$$r = 3; y = [2, 0, 1]^T$$
$$\Downarrow$$
$$y_{onehot} = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$f(x; \theta) = X\theta = \hat{y},$$

$$x \in \mathbb{R}^{N \times d}; \theta \in \mathbb{R}^{d \times r}; y \in \mathbb{R}^{N \times r}$$

- Analitična rešitev za najboljši θ :

$$\mathcal{L}(\theta) = \frac{1}{2} \|y_{onehot} - f(x; \theta)\|_2^2$$

Zgled – analitična rešitev

- Metoda najmanjših kvadratov,
- Število učnih vzorcev ... N
- Število značilk ... d
- Število razredov ... r

$$y = [2, 0, 1]^T$$
$$\Downarrow$$
$$y_{onehot} = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$f(x; \theta) = X\theta = \hat{y},$$

$$x \in \mathbb{R}^{N \times d}; \theta \in \mathbb{R}^{d \times r}; y \in \mathbb{R}^{N \times r}$$

- Analitična rešitev za najboljši θ :

$$\theta_{opt} = (X^T X)^{-1} X^T y$$

Zgled – iterativna rešitev

- Globoka nevronska omrežja
- θ je množica vseh parametrov:
- $\theta = \{w_1, w_2, \dots, w_{n_{param}}\}$




Figure 12.2 Deep network architecture with multiple layers.

- Optimizacija preko gradientne metode:

$$\mathcal{L}(\theta) = - \sum_{x,y \in U} \sum_{c=1}^r \log \left(\frac{e^{x_c}}{\sum_{i=1}^c e^{x_i}} y_c \right)$$

Zgled – iterativna rešitev

- Globoka nevronska omrežja
- θ je množica vseh parametrov:
- $\theta = \{w_1, w_2, \dots, w_{n_{param}}\}$




Figure 12.2 Deep network architecture with multiple layers.

- Optimizacija preko gradientne metode:

$$\nabla \mathcal{L}(x; \theta) = \left\{ \frac{\partial \mathcal{L}(x; \theta)}{\partial w_1}, \dots, \frac{\partial \mathcal{L}(x; \theta)}{\partial w_{n_{param}}} \right\}$$

Zgled – iterativna rešitev

- Globoka nevronska omrežja
- θ je množica vseh parametrov:
- $\theta = \{w_1, w_2, \dots, w_{n_{param}}\}$


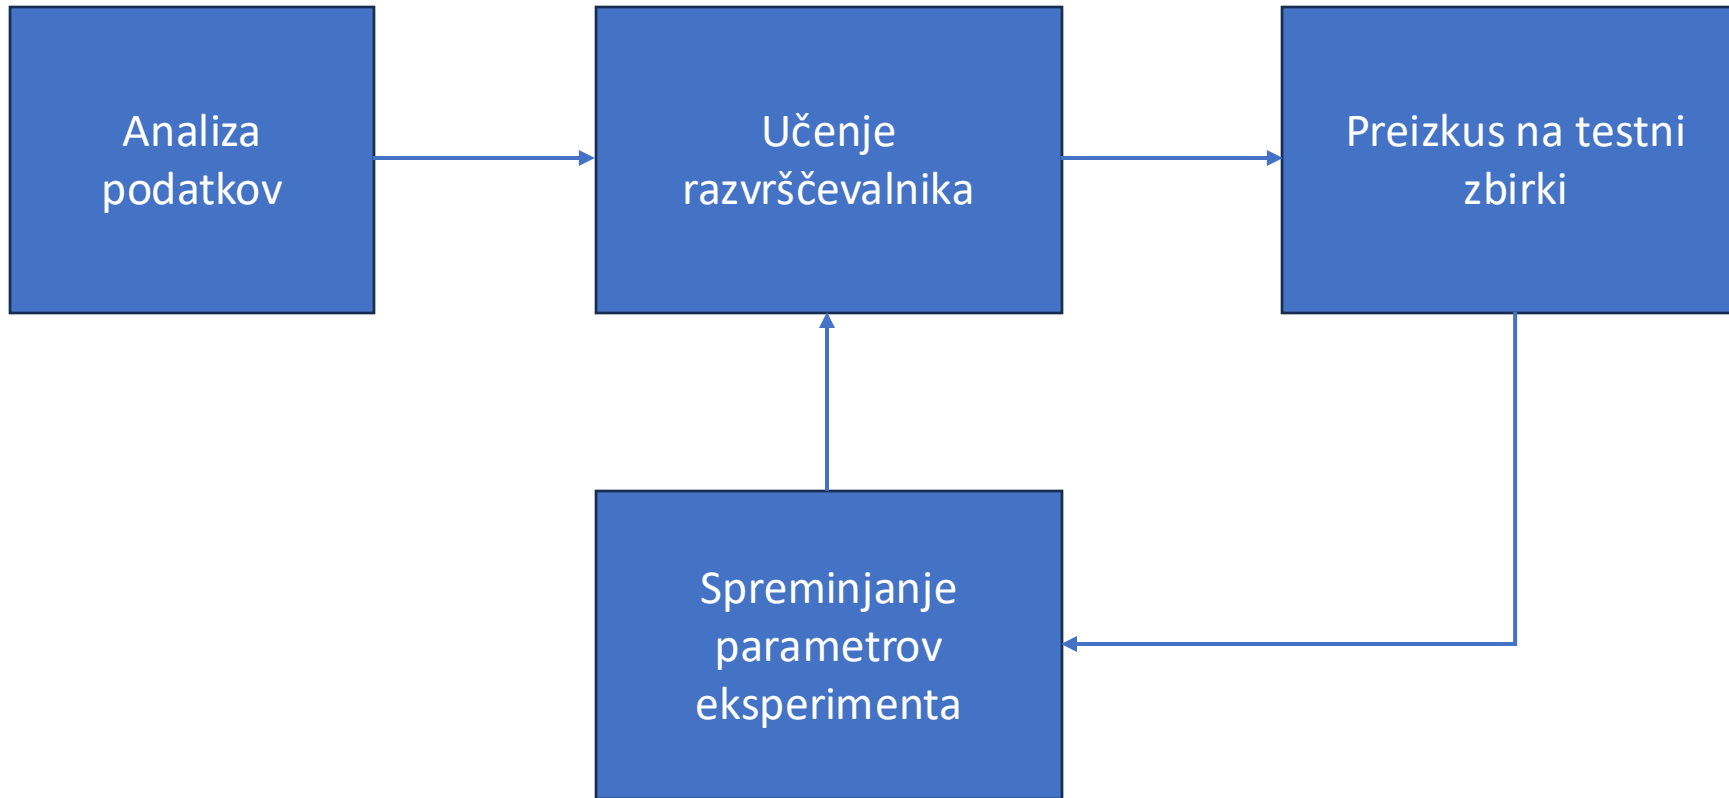


Figure 12.2 Deep network architecture with multiple layers.

- Optimizacija preko gradientne metode:

$$\theta_{t+1} \leftarrow \theta_t - \eta \nabla \mathcal{L}(\theta)$$

Zgradba eksperimenta



Preizkus znanja

- Ovrednoti odvisnost natančnosti od števila učnih primerov
 - Z naključnim vzorčenjem in raztrosom
 - gl. **matplotlib.pyplot.boxplot**
- Preizkusi razvrščanje z metodo najmanjših kvadratov
 - gl. **numpy.linalg.lstsq**
 - Preizkus z izvornimi oz. z one-hot oznakami